
Dropout & Statch-Normalization

Contents

- 1. Dropout
- 2. Batch-Normalization


Why?




DNN

-> Training data가 많이 필요, 학습 시간이 길어짐, overfitting을 피하기 힘듦.


NN의 고질적인 문제인 over-fitting 문제를 완화시킬 수 있는 방법 중 하 나.



- Very high accuracy on the training dataset (eg: 0.99)
- Poor accuracy on the test data set (0.85)



(a) Standard Neural Net




(b) After applying dropout.


layer에 포함된 weight 중에서 일부만 참여시킴.

난수를 사용해서 일부 뉴런을 0 으로 만드는 방법.

일정한 mini-batch 구간 동안 dropout된 망에 대한 학습을 끝 내면, 다시 무작위로 다른 뉴런 들을 dropout하면서 반복적으 로 학습.



(a) Standard Neural Net



(b) After applying dropout.

 Voting 효과 – mini batch 구 간 동안 dropout된 각자의 망에 피팅이 되고 평균 효과 를 얻을 수 있음.

2. Co-adaptation 효과 – 특정 뉴런의 바이어스나 가중치가 큰 값을 갖게 되면 그 영향이 커지면서 다른 뉴런들의 학 습 속도가 느려 지거나 학습 이 제대로 되지 않음. 결과 적으로 이런 뉴런의 영향을 받을 확률이 적음.

```
keep_prob = tf.placeholder("float")
h_fc1_drop = tf.nn.dropout(h_fc1, keep_prob)
```

```
keep_prob = tf.placeholder("float")
h_fc1_drop = tf.nn.dropout(h_fc1, keep_prob)
```

일정한 mini-batch 구간 동안 생략 된 망에 대한 학습을 끝내면, 다 시 무작위로 다른 뉴런들을 생략 (dropout) 하면서 반복적으로 학 습함.


```
cross entropy = -tf.reduce sum(y *tf.log(y conv))
train step = tf.train.AdamOptimizer(1e-4).minimize(cross_entropy)
correct prediction = tf.equal(tf.argmax(y conv,1), tf.argmax(y ,1))
accuracy = tf.reduce mean(tf.cast(correct prediction, "float"))
sess.run(tf.initialize all variables())
for i in range(20000):
    batch = mnist.train.next batch(50)
    if i%100 == 0:
       train accuracy = accuracy.eval(feed dict={x:batch[0], y : batch[1], keep prob: 1.0})
        print "step %d, training accuracy %g" % (i, train_accuracy)
   train_step.run(feed_dict={x: batch[0], y_: batch[1], keep_prob: 0.5})
print "test accuracy %g" % accuracy.eval(feed dict={x: mnist.test.images, y : mnist.test.labels, keep prob: 1.0})
```


Test 시에는 모든 layer의 노드 활성화

Dropout

```
keep prob = tf.placeholder("float")
h_fc1_drop = tf.nn.dropout(h_fc1, keep_prob)
cross entropy = -tf.reduce sum(y *tf.log(y conv))
train_step = tf.train.AdamOptimizer(1e-4).minimize(cross_entropy)
correct prediction = tf.equal(tf.argmax(y conv,1), tf.argmax(y ,1))
accuracy = tf.reduce mean(tf.cast(correct prediction, "float"))
sess.run(tf.initialize all variables())
for i in range(20000):
    batch = mnist.train.next batch(50)
    if i%100 == 0:
       train accuracy = accuracy.eval(feed dict={x:batch[0], y : batch[1], keep prob: 1.0})
        print "step %d, training accuracy %g" % (i, train_accuracy)
    train_step.run(feed_dict={x: batch[0], y_: batch[1], keep_prob: 0.5})
print "test accuracy %g" % accuracy.eval(feed_dict={x: mnist.test.images, y_: mnist.test.labels, keep_prob: 1.0}
```


Why?





학습시켜야 되는 Parameter가 많음.


Activation function, Initialization method의 한계.



학습시켜야 되는 Parameter가 많음.


Activation function, Initialization method의 한계.

Weight의 조그만 변화가 가중되어 쌓이면 Hidden layer를 올라갈수록 값의 변화가 큼




Internal Covariate Shift(**내부 공변량 변화)**-> 이전에 학습 했던 노드의 분포와 다음
에 학습하는 분포가 다르게 되는 것

결과적으로 학습이 힘듦.



Layer 상단으로 갈수록 노드의 분포 변화가 더 심해짐.




해결법

Weight Initialization을 잘한다.

Learning rate를 줄인다.


->어렵고 학습 속도가 느림.



Weight값이 가중되어서 히든 layer의 노드 값이 변화하는 범위가 적으면 학습이 잘 될 것이다라는 가정을 함.

BN을 이용해서 해보겠다~


간단히 activation function에 들어가기 전 input의 range를 restrict하는 것.




 $y_i \leftarrow \gamma \hat{x}_i + \beta \equiv \text{BN}_{\gamma,\beta}(x_i) // \text{ scale and shift}$

$$y_i \leftarrow \gamma \hat{x}_i + \beta \equiv BN_{\gamma,\beta}(x_i)$$

// scale and shift






```
with tf.name scope('dnn'):
   # batch normalization layer using partial
   batch norm layer = partial(
           tf.layers.batch normalization,
           training=training,
           momentum=batch norm momentum)
   # 1st - hidden
   hidden1 = tf.layers.dense(inputs, n hidden1, name="hidden1")
   # batch norm
   bn1 = batch norm layer(hidden1)
   # activation function
   bn1 act = tf.nn.elu(bn1)
   # 2nd - hidden
   hidden2 = tf.layers.dense(bn1 act, n hidden2, name="hidden2")
   bn2 = batch norm layer(hidden2)
   bn2 act = tf.nn.elu(bn2)
   # outputs
   logits before bn = tf.layers.dense(bn2 act, n outputs, name="outputs")
   logits = batch norm layer(logits before bn)
```

Tensorflow에서는 tf.nn.batch_normalization()과 tf.layers.batch_normalization()을 통해 BN 기능을 제공

전자의 경우 Mean, Variance값(학습시, 테 스트시) 각각 계산해 인자로 넘겨주어야 하 고 Scaling, Shift factor의 경우도 따로 만들 어 줘야한다.

후자의 경우 다 해줌~



- Test 단계
- 데이터가 하나씩 들어간다면, mean, variance를 계산할 mini-batch가 없기 때문에 전체 Training Set의 평균과 표준편차를 사용.
- 계산량이 많은 경우 Normalization 에 필요한 mean, variance를, 그동 안 계산했던 mean, variance의 평균 으로 놓고 output을 구한다.

- Tanh, Sigmoid같은 활성화 함수에 대해 vanishing gradient 문제가 감소한다.
- 가중치 초기화에 덜 민감.
- Learning rate를 크게 잡아도 GD가 잘 수렴.
- Overfitting 억제, drop out 필요성 감소

