


딥러닝 세미나 Season #6

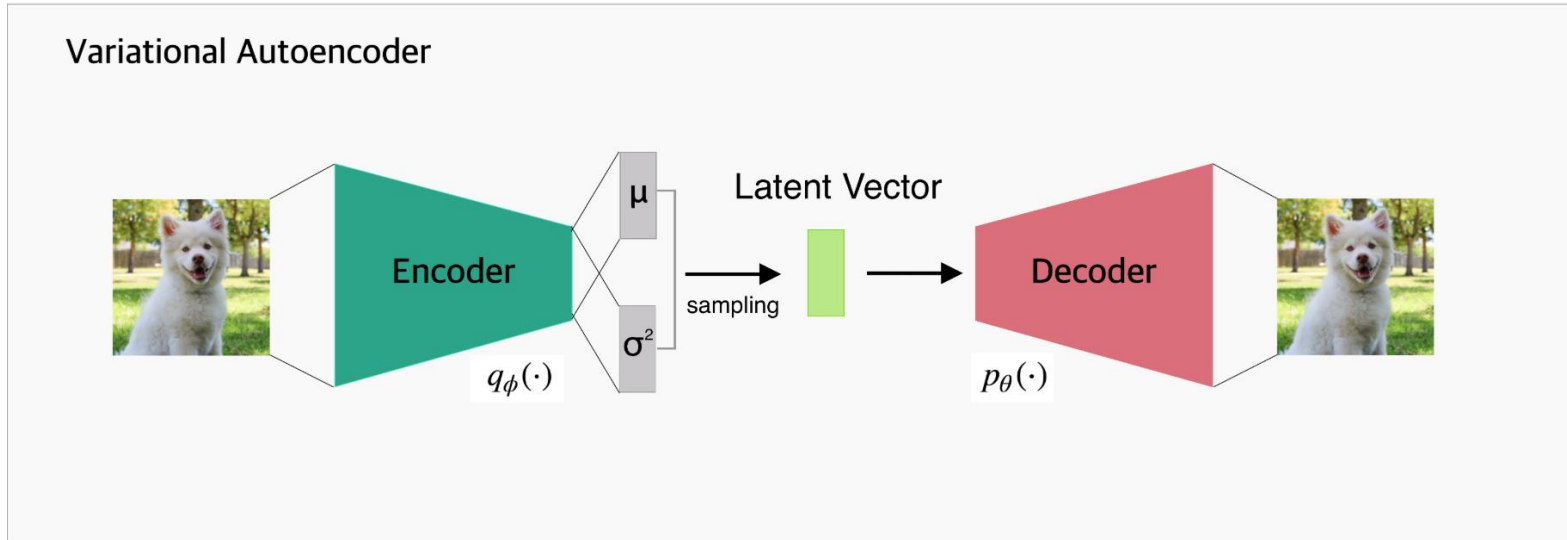
VAE

한양대학교 인공지능연구실
조충현





VAE?



- VAE는 생성 모델(Generative Model)중 하나로, 확률분포 $P(x)$ 를 학습함으로써, 데이터를 생성하는 것이 목표
- Encoder에서는 학습용 데이터(이하 x)를 입력으로 받고 잠재변수(이하 z)의 확률분포에 대한 파라미터 출력
- Decoder는 잠재변수에 대한 확률 분포 $p(z)$ 에서 샘플링한 벡터를 입력 받아 원본 이미지 복원






VAE 목표

1. 주어진 데이터를 잘 설명하는 잠재변수의 분포를 찾는 것(Encoder의 역할)
2. 잠재변수로 부터 원본 이미지와 같은 이미지를 잘 복원하는 것(Decoder의 역할)



잠재변수?




- 잠재변수는 encoder에서 입력 데이터를 추상화하여 잠재적인 특징을 추출해서 나온 것
- 또한 decoder에서는 이러한 잠재적 특징을 바탕으로 원 데이터로 복원하는 역할



Encoder

Encoder의 역할

- 데이터가 주어졌을 때 Decoder가 원래의 데이터로 잘 복원할 수 있는 z 를 샘플링 할 수 있는 이상적인 확률분포 $p(z|x)$ 를 찾는 것



But!!

- 어떤 것이 이상적인 확률분포 인지는 아무도 모른다!!!



Variational inference



- 변분추론이란, 계산이 어려운 확률분포를 추정하기 위해서 다루기 쉬운 분포(approximation class, q_ϕ)를 가정
이 확률분포의 모수를 바꿔가며, 이상적인 확률분포에 근사하게 만들어 그 확률분포를 대신 사용
- Encoder는 ϕ 라는 파라미터들을 바꾸어가며, $q_\phi(z|x)$ 확률 분포를 이상적인 확률분포 $p(z|x)$ 에 근사시키는 역할을 수행
- 보통 q_ϕ 은 Gaussian 정규 분포라 가정한다. 그리고 이 때 z 의 marginal distribution은 평균이 0이고 분산이 1인 표준 정규분포로 가정



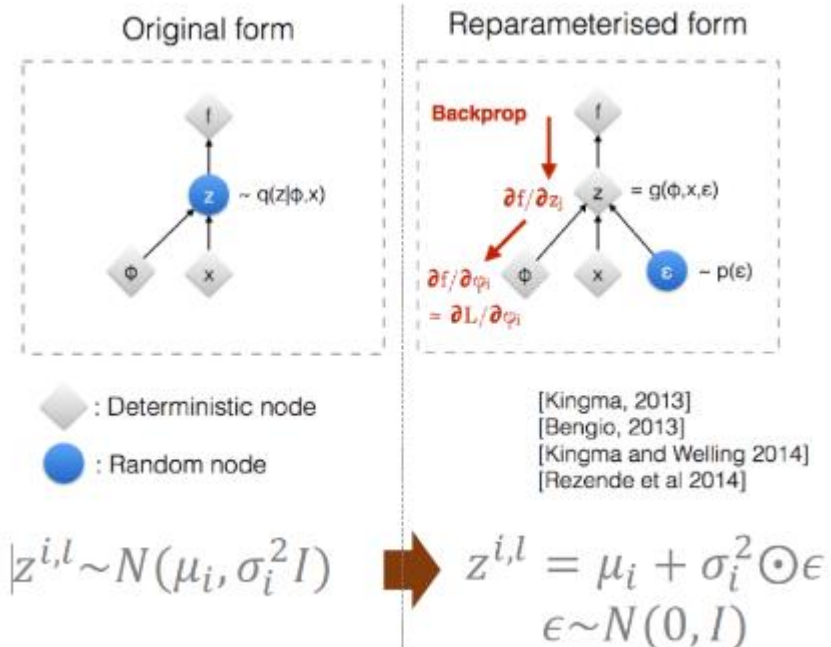
Reparameterization trick

$$z = \mu(x) + \sigma(x) \times \epsilon, \quad \epsilon \sim N(0, 1)$$

잠재변수 z 를 샘플링 하기 위해 사용하는 트릭

왜?

- 이 트릭을 사용하면 역전파를 통해 Encoder가 산출하면 평균과 분산을 업데이트 할 수 있다.

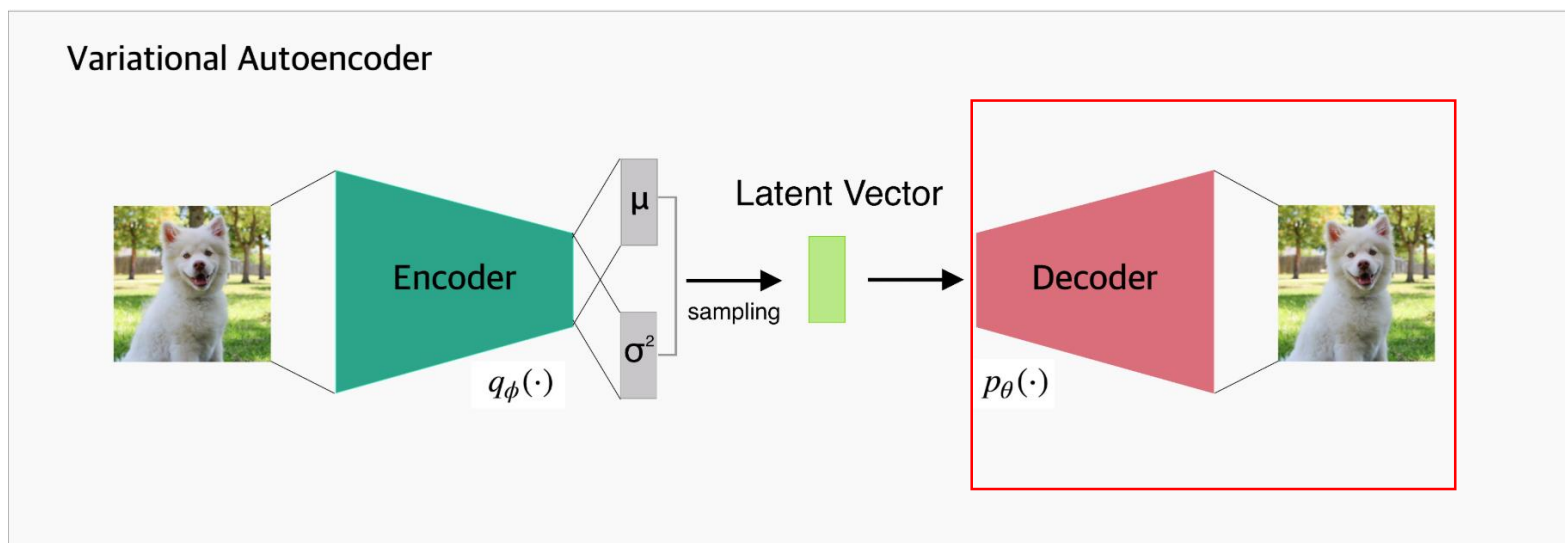




Decoder

Decoder의 역할

- 추출한 샘플을 입력으로 받아, 다시 원본으로 재구축하는 역할을 수행





Decoder

$p(x)$ 실제 데이터의 분포

$$\log(p(x)) = \log\left(\int p(x, z) dz\right) = \log\left(\int p(x|z)p(z) dz\right) \xrightarrow{q_\phi(z|x)} \log(p(x)) = \log\left(\int p(x|z) \frac{p(z)}{q_\phi(z|x)} q_\phi(z|x) dz\right)$$

Jensen's Inequality


$$\log(p(x)) \geq \int \log\left(p(x|z) \frac{p(z)}{q_\phi(z|x)}\right) q_\phi(z|x) dz \xrightarrow{\text{최종}} \log(p(x)) \geq \int \log(p(x|z)) q_\phi(z|x) dz - \int \log\left(\frac{q_\phi(z|x)}{p(z)}\right) q_\phi(z|x) dz$$

최종 식의 우변식이 Evidence LowerBOund 줄어서 ELBO라고 부른다.

이 $\text{ELBO}(\phi)$ 값을 최대화하는 ϕ 를 찾으면 최종식의 우변과 좌변은 같게 된다.



ELBO 와 KL의 관계



$$\log(p(x)) = \int \log(p(x)) q_\phi(z|x) dz$$

$$\begin{aligned} \log(p(x)) &= \int \log\left(\frac{p(x, z)}{q_\phi(z|x)}\right) q_\phi(z|x) dz + \int \log\left(\frac{q_\phi(z|x)}{p(z|x)}\right) q_\phi(z|x) dz \end{aligned}$$

↑
ELBO(ϕ)

↑
 $KL(q_\phi(z|x) || p(z|x))$

따라서 위의 그림처럼 ELBO(ϕ)를 최대화하는 것이 곧, $KL(q_\phi(z|x) || p(z|x))$ 를 최소화 하는 것



ELBO

$$\begin{aligned} \int \log(p(x|z)) q_\phi(z|x) dz &= \mathbb{E}_{q_\phi(z|x)} [\log(p(x|z))] \\ \int \log\left(\frac{q_\phi(z|x)}{p(z)}\right) q_\phi(z|x) dz &= KL(q_\phi(z|x) \| p(z)) \end{aligned} \quad \longrightarrow \quad ELBO(\phi) = \mathbb{E}_{q_\phi(z|x)} [\log(p(x|z))] - KL(q_\phi(z|x) \| p(z))$$

$\log(p(x|z)) \rightarrow \log(p_\theta(x|z))$ 표현하면 θ 를 조정하여 최대하는 것

따라서, 최종 VAE의 Loss 함수는 아래와 같다

$$\mathcal{L}_{(\theta, \phi; x^i)} = - \mathbb{E}_{q_\phi(z|x^i)} [\log(p_\theta(x^i|z))] + KL(q_\phi(z|x^i) \| p(z))$$



Loss

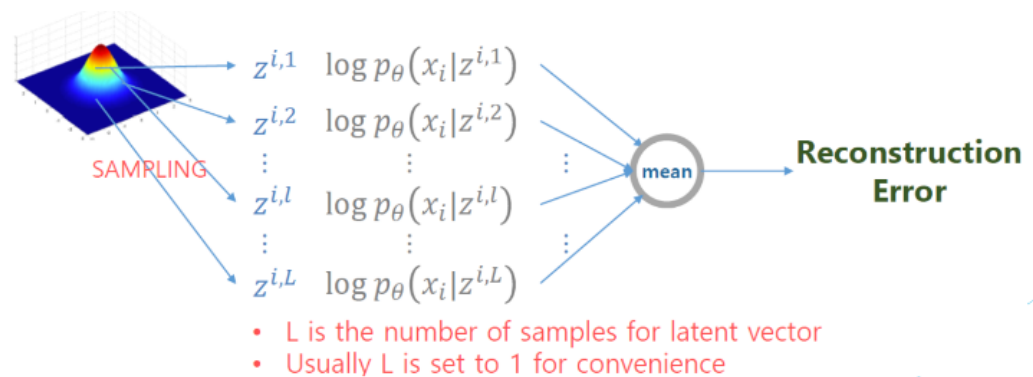
1. Expectation

$$\mathbb{E}_{q_\phi(z|x^i)}[\log(p_\theta(x^i|z))] \approx \frac{1}{L} \sum_{z^{i,l}} \log(p_\theta(x^i|z^{i,l}))$$

딥러닝의 특성상 Mini-batch로 학습하기 때문에 q_ϕ 로 부터 L개의 데이터를 샘플링하여, Monte-carlo 방식으로 위와 같이 구한다.

이 때, $p(x)$ 를 Bernoulli 분포로 가정하면, $\log(p_\theta(x^i|z^{i,l}))$ 값은 Cross Entropy 식이 된다.

$$\begin{aligned} \log(p_\theta(x^i|z^i)) &= \log \prod_{j=1}^D p_\theta(x_{i,j}|z^i) \\ &= \sum_{j=1}^D \log p_\theta(x_{i,j}|z^i) \\ &= \sum_{j=1}^D \log p_{i,j}^{x_{i,j}} (1 - p_{i,j})^{1-x_{i,j}} \\ &= \sum_{j=1}^D x_{i,j} \log p_{i,j} + (1 - x_{i,j}) \log(1 - p_{i,j}) \end{aligned}$$





Loss

2. KL

$$\begin{aligned}
 KL(q_\phi(z|x^i)||p(z)) &= \frac{1}{2} \left\{ \text{tr}(\sigma_i^2) + \mu_i^T \mu_i - J + \ln \frac{1}{\prod_{j=1}^J \sigma_{j,j}^2} \right\} \\
 &= \frac{1}{2} \left\{ \sum_{j=1}^J \sigma_{i,j}^2 + \sum_{j=1}^J \mu_{i,j}^2 - J - \sum_{j=1}^J \ln(\sigma_{i,j}^2) \right\} \\
 &= \frac{1}{2} \sum_{j=1}^J (\mu_{i,j}^2 + \sigma_{i,j}^2 - \ln(\sigma_{i,j}^2) - 1)
 \end{aligned}$$

여기서 KL값 계산을 쉽게 하기 위해서 $q_\phi(z|x^i)$ 와 $p(z)$ 를 정규분포로 가정했다.

Kullback-Leibler divergence [\[edit\]](#)

The Kullback-Leibler divergence from $\mathcal{N}_0(\mu_0, \Sigma_0)$ to $\mathcal{N}_1(\mu_1, \Sigma_1)$, for non-singular matrices Σ_0 and Σ_1 , is:^[8]

$$D_{\text{KL}}(\mathcal{N}_0||\mathcal{N}_1) = \frac{1}{2} \left\{ \text{tr}(\overset{\text{posterior}}{\Sigma_1^{-1} \Sigma_0}) + (\mu_1 - \overset{\text{prior}}{\mu_0})^T \Sigma_1^{-1} (\mu_1 - \mu_0) - k + \ln \frac{|\Sigma_1|}{|\Sigma_0|} \right\},$$

where k is the dimension of the vector space.



Loss

원 데이터에 대한 likelihood 선택

Variational inference를 위한
approximation class 중 선택

다루기 쉬운 확률 분포 중 선택

$$L_i(\phi, \theta, x_i) = \underbrace{-\mathbb{E}_{q_\phi(z|x_i)}[\log(p_\theta(x_i|z))]}_{\text{Reconstruction Error}} + \underbrace{KL(q_\phi(z|x_i)||p(z))}_{\text{Regularization}}$$

Reconstruction Error

- 현재 샘플된 z 에 대한 negative log likelihood
- x_i 에 대한 복원 오차 (AutoEncoder 관점)

Regularization

- 현재 샘플된 z 에 대한 추가 조건
- 샘플링되는 z 들에 대한 통제성을 prior를 통해 부여, Variational distribution $q(z|x)$ 가 $p(z)$ 와 유사해야 한다는 조건을 부여




VAE의 장단점

장점

- VAE는 GAN에 비해 학습이 안정적인 편
(왜? Reconstruction error와 같이 평가 기준이 명확)
- 내재한 잠재변수 z 도 함께 학습 할 수 있는 장점(feature learning)

단점

- 오른쪽 결과 처럼 출력이 선명하지 않고 평균값 형태로 표시되는 문제
- reparameterization trick이 모든 경우에 적용되지 않는 문제





Q&A